

## 23 | 文本分类：如何区分特定类型的新闻？

2019-02-06 黄申

程序员的数学基础课

[进入课程 >](#)



讲述：黄申

时长 15:03 大小 13.79M



你好，我是黄申。

你平时应该见过手机 App 推送的新闻吧？你有没有觉得这些 App 的推荐算法很神奇？它们竟然可以根据你的喜好来推荐新闻。想要实现这些推荐算法，有一个非常重要的步骤就是给新闻分类。可是，新闻头条这种综合性的平台，需要处理的新闻都是海量的，我们不可能完全靠人工手动处理这些事情。这个时候，我们就要用到计算机技术，来对文本进行自动分类。

上一节，我给你介绍了如何利用朴素贝叶斯方法，教会计算机进行最基本的水果分类。基于水果分类，今天我们继续深入分类这个话题，告诉你如何利用自然语言处理和朴素贝叶斯方法，对新闻这种长篇文本进行分类。

# 文本分类系统的基本框架

想要实现一个完整的文本分类系统，我们通常需要进行这些步骤：

## 1. 采集训练样本

对于每个数据对象，我们必须告诉计算机，它属于哪个分类。上一节的水果案例里，我们给每个水果打上“苹果”“甜橙”和“西瓜”的标签，这就是采集训练样本。

同样，我们可以给每一篇新闻打上标签，也就是说，我们首先要分辨某条新闻是什么类型的，比如是政治的、军事的、财经的、体育的，还是娱乐的等等。这一点非常关键，因为分类标签就相当于计算机所要学习的答案，其质量高低直接决定了计算机的分类效果。此外，我们也可以在一开始就预留一些训练样本，专门用于测试分类的效果。

## 2. 预处理自然语言

在水果的案例中，当我们把这些水果的特征值提取出来后，能很容易地将它们的属性转化成计算机所能处理的数据，可是这一步对于文本而言就没有那么容易了。好在专家们已经发明出了一套相对成熟的方法，包括词包（bag of words）、分词、词干（Stemming）和归一化（Normalization）、停用词（Stopword）、同义词（Synonyms）和扩展词处理。这里你只需要了解有这么些方法就可以了，我们使用这些方法的目的是让计算机能够理解文本，所以如果你对刚才提到的这些专业词汇比较陌生，完全不用担心，这并不会影响对后面知识的理解。


## 3. 训练模型

训练模型就是算法通过训练数据进行模型拟合的过程。对于朴素贝叶斯方法而言，训练的过程就是要获取每个分类的先验概率、每个属性的先验概率以及给定某个分类时，出现某个属性的条件概率。

## 4. 实时分类预测

算法模型在训练完毕后，根据新数据的属性来预测它属于哪个分类的过程。对于朴素贝叶斯方法而言，分类预测的过程就是根据训练阶段所获得的先验概率和条件概率，来预估给定一系列属性的情况下属于某个分类的后验概率。

整个流程大致可以用下图来描述：



这四个步骤你大致了解就可以了，这里面有两点我会重点讲一下，一是对文本中的自然语言进行预处理，并从文本集合建立字典；另一个是如何使用建好的字典，统计朴素贝叶斯方法所需的数据。自然语言的预处理是让计算机“理解”人类语言的关键步骤，如果没有这一步，计算机就无法将大量的自然语言转换成自己可以处理的数据。而条件概率和先验概率是朴素贝叶斯方法所必须的，因此如何准确地统计它们也是需要详细解释的。

## 基于自然语言的预处理

和之前的水果案例相比，新闻这种文本数据最大的区别在于，它包含了大量的自然语言。那么如何让计算机理解自然语言呢？我们的计算机体系没有思维，要理解人类的语言在现阶段是不现实的。但是，我们仍然可以对自然语言进行适当的处理，将其变为机器所能处理的数据。

首先，我们要知道，文本的重要属性是什么，这样我们才能提取出它的特征。怎么才能知道哪些属性是重要的呢？

我举个例子，假如说，有人给你一篇几千字的文章，让你在 10 秒钟之内说出文章大意，你会怎么办？我想大部分人的解决方案是“找关键词”！没错，我们也可以交给计算机用同样的办法。而计算机处理文本的基本单位就是字和单词，这就是人们最常用的方法：词袋（Bag of words）模型。


这种模型会忽略文本中的词语出现的顺序以及相应的语法，将整篇文章仅仅看做是一个大量单词的组合。文本中每个词的出现都是独立的，不依赖于其他词的出现情况。讲到这里，你有没有发现在词包模型中，所有单词相互之间是独立的，这个假设和朴素贝叶斯模型的独立假设是不是一致呀？

没错！这里我们就可以很巧妙地将朴素贝叶斯和文本处理结合起来了。不过先不要急，我们还要掌握一些方法，才能将文本中的长篇大论处理成关键词。

### 1. 分词

计算机处理自然语言的基本单位是单词和词组。对于英语等拉丁语系的语言来说，单词之间是以空格作为自然分界符的，所以我们可以直接使用空格对句子进行分割，然后来获取每个单词。但是，中文、日文、韩文这些语言在书写的时候，词和词之间并没有空格可以进行自然分界，所以我们就需要使用一些算法，来估计词语之间的划分，我们将这个过程称为**分词**。

这里有一个给中文句子分词的例子，你可以看一看。

 复制代码

- 1 分词前：今天我们一起学习计算机学科中的数学知识
- 2 分词后：今天 我们 一起 来 学习 计算机 学科 中 的 数学 知识


是不是觉得给句子分词很简单？这是因为你的中文水平比较高，你想想，计算机怎么才能知道如何分词呢？我们有很多现成的分词模型可以使用。我这里介绍两种目前比较主流的分词模型，你只需要了解就行。

第一种是**基于字符串匹配**。其实就是扫描字符串。如果发现字符串的子串和词相同，就算匹配成功。匹配规则通常是“正向最大匹配”“逆向最大匹配”“长词优先”。这些算法的优点是只需使用基于字典的匹配，因此计算复杂度低；缺点是处理歧义词效果不佳。

第二种是**基于统计和机器学习**。这类分词基于人工标注的词性和统计特征，对中文进行建模。训练阶段，根据标注好的语料对模型参数进行估计。在分词阶段再通过模型计算各种分词出现的概率，将概率最大的分词作为最终结果。常见的序列标注模型有**隐马尔科夫模型**（HMM，Hidden Markov Model）和**条件随机场**（CRF，Conditional Random Field），我们后面章节会讲到，这里我先不展开。

## 2. 取词干和归一化

我们刚才说了，相对中文而言，英文完全不需要考虑分词。不过它也有中文不具有的单复数、各种时态，因此它需要考虑**取词干**（stemming）。取词干的目标就是为了减少词的变化形式，将派生词转化为基本形式，就像下面这样：

 复制代码

- 1 将 am, is, are, was, were 全部转换为 be
- 2 将 car, cars, car's, cars' 全部转换为 car

最后，我们还要考虑大小写转化和多种拼写（例如 color 和 colour）这样的统一化，我们把这种做法称为**归一化**。


### 3. 停用词

无论何种语言，都会存在一些不影响（或基本不影响）相关性的词。有的时候干脆可以指定一个叫**停用词**（stop word）的字典，直接将这些词过滤，不予以考虑。例如英文中的 a、an、the、that、is、good、bad 等。中文“的、个、你、我、他、好、坏”等。

如此一来，我们可以在基本不损失语义的情况下，减少数据文件的大小，提高计算机处理的效率。当然，也要注意停用词的使用场景，例如用户观点分析，good 和 bad 这样的形容词反而成为了关键。不仅不能过滤，反而要加大它们的权重。

### 4. 同义词和扩展词

不同的地域或者不同时代，会导致人们对于同样的物品叫法也不同。例如，在中国北方“番茄”应该叫“西红柿”，而台湾地区将“菠萝”称为“凤梨”。对于计算机而言，需要意识到这两个词是等价的。添加同义词就是一个很好的手段。我们可以维护如下一个同义词的词典：

 复制代码

- 1 番茄，西红柿
- 2 菠萝，凤梨
- 3 洋山芋，土豆
- 4 泡面，方便面，速食面，快餐面
- 5 山芋，红薯
- 6 鼠标，滑鼠
- 7 .....

有了这样的词典，当看到文本中出现“番茄”关键词的时候，计算机系统就会将其等同于“西红柿”这个词。有的时候我们还需要扩展词。如果简单地将 Dove 分别和多芬、德芙简单地等价，那么多芬和德芙这两个完全不同的品牌也变成了同义词，这样做明显是有问题的。那么我们可以采用扩展关系，当系统看到文本中的“多芬”时将其等同于“Dove”，看到“德芙”时将其等同于“Dove”。但是看到“Dove”的时候并不将其等同于“多芬”或“德芙”。

通过词包模型的假设，以及上述这些自然语言处理的方法，我们可以将整篇的文字，切分为一个个的单词，这些是表示文章的关键属性。你不难发现，每个单词可以作为文章的属性，而通过这些单词的词频（出现的频率），我们很容易进行概率的统计。下面我对分类的先验概率、单词的先验概率、某个分类下某个单词的条件概率分别给出了示例。

分类	数量	先验概率	单词总词频
政治	1000	20%	726,898
军事	800	16%	897,213
财经	900	18%	311,241
体育	1100	22%	549,329
娱乐	1200	24%	353,210
总计	5000	100%	2,837,891

单词	词频	先验概率
中国	300	0.0106%
美国	80	0.0028%
电影	90	0.0032%
奥运	50	0.0018%
清宫戏	150	0.0053%
世界杯	40	0.0014%
航母	80	0.0028%
...	...	...
总计	2,837,891	100%



分类	单词	词频	条件概率
政治	中国	80	0.0110%
军事	中国	100	0.0111%
财经	中国	50	0.0161%
体育	中国	40	0.0073%
娱乐	中国	30	0.0075%
政治	美国	80	0.0028%
军事	美国	...	...
...	...	...	...
政治	航母	25	0.0034%
军事	航母	48	0.0053%
财经	航母	7	0.0022%
体育	航母	0 (1)	0.0002%
娱乐	航母	0 (1)	0.0003%
...	...	...	...
/	总计	2,837,891	/

在上表中，你会发现某些单词从未在某个分类中出现，例如“航母”这个词从未在“体育”和“娱乐”这两个分类中出现。对于这种情况，我们可以使用**平滑**（smoothing）的技术，将其词频或条件概率设置为一个极小的值。这里，我设置了最小的词频，也就是 1。

有了这些单词属性以及相应的概率统计，下一步就是如何使用朴素贝叶斯模型进行文本的分类了。

## 运用朴素贝叶斯模型

首先我们先来回顾下，上一节推导的朴素贝叶斯公式。

$$\begin{aligned}
 P(c|o) &= P(c|f_i, f_j) = P(c|f_i) \times P(c|f_j) \\
 &= \frac{P(f_i|c) \times P(c)}{P(f_i)} \times \frac{P(f_j|c) \times P(c)}{P(f_j)}
 \end{aligned}$$

在新闻分类中，**o**就表示一篇文章，而**c**表示新闻的种类（包括政治、军事、财经等等）。而属性字段**f**就是我们从文档集而建立的各种单词。公式等号左边的 **$P(c|f)$** 就是待分类新闻中，出现单词 **f** 时，该新闻属于类别 **c** 的概率。而等号右边的  **$P(f|c)$**  是根据训练数据统计，得到分类 **c** 中出现单词 **f** 的概率。 **$P(c)$**  是分类 **c** 在新闻训练数据中出现的概率， **$P(f)$**  是单词 **f** 在训练样本中出现的概率。

我们用刚才表格中的数据来计算下“中国航母”这个短语属于每个分类的概率。

$$\begin{aligned}
 P(\text{政治} | \text{中国航母}) &= P(\text{政治} | \text{中国}, \text{航母}) \\
 &= P(\text{政治} | \text{中国}) \times P(\text{政治} | \text{航母}) \\
 &= \frac{P(\text{中国} | \text{政治}) \times P(\text{政治})}{P(\text{中国})} \times \frac{P(\text{航母} | \text{政治}) \times P(\text{政治})}{P(\text{航母})} \\
 &= \frac{0.0110\% \times 20\%}{0.0106\%} \times \frac{0.0034\% \times 20\%}{0.0028\%} \\
 &= 20.7547\% \times 24.2857\% \\
 &= 5.04\%
 \end{aligned}$$

$$\begin{aligned}
 P(\text{军事} | \text{中国航母}) &= P(\text{军事} | \text{中国}, \text{航母}) \\
 &= P(\text{军事} | \text{中国}) \times P(\text{军事} | \text{航母}) \\
 &= \frac{P(\text{中国} | \text{军事}) \times P(\text{军事})}{P(\text{中国})} \times \frac{P(\text{航母} | \text{军事}) \times P(\text{军事})}{P(\text{航母})} \\
 &= \frac{0.0111\% \times 16\%}{0.0106\%} \times \frac{0.0053\% \times 16\%}{0.0028\%} \\
 &= 16.7547\% \times 30.2857\% \\
 &= 5.07\%
 \end{aligned}$$



$$\begin{aligned}
P(\text{财经} | \text{中国航母}) &= P(\text{财经} | \text{中国}, \text{航母}) \\
&= P(\text{财经} | \text{中国}) \times P(\text{财经} | \text{航母}) \\
&= \frac{P(\text{中国} | \text{财经}) \times P(\text{财经})}{P(\text{中国})} \times \frac{P(\text{航母} | \text{财经}) \times P(\text{财经})}{P(\text{航母})} \\
&= \frac{0.0161\% \times 18\%}{0.0106\%} \times \frac{0.0022\% \times 18\%}{0.0028\%} \\
&= 27.3396\% \times 14.1429\% \\
&= 3.87\%
\end{aligned}$$

$$\begin{aligned}
P(\text{体育} | \text{中国航母}) &= P(\text{体育} | \text{中国}, \text{航母}) \\
&= P(\text{体育} | \text{中国}) \times P(\text{体育} | \text{航母}) \\
&= \frac{P(\text{中国} | \text{体育}) \times P(\text{体育})}{P(\text{中国})} \times \frac{P(\text{航母} | \text{体育}) \times P(\text{体育})}{P(\text{航母})} \\
&= \frac{0.0073\% \times 22\%}{0.0106\%} \times \frac{0.0002\% \times 22\%}{0.0028\%} \\
&= 15.1509\% \times 1.5714\% \\
&= 0.2381\%
\end{aligned}$$

$$\begin{aligned}
P(\text{娱乐} | \text{中国航母}) &= P(\text{娱乐} | \text{中国}, \text{航母}) \\
&= P(\text{娱乐} | \text{中国}) \times P(\text{娱乐} | \text{航母}) \\
&= \frac{P(\text{中国} | \text{娱乐}) \times P(\text{娱乐})}{P(\text{中国})} \times \frac{P(\text{航母} | \text{娱乐}) \times P(\text{娱乐})}{P(\text{航母})} \\
&= \frac{0.0075\% \times 24\%}{0.0106\%} \times \frac{0.0003\% \times 24\%}{0.0028\%} \\
&= 16.98\% \times 2.5714\% \\
&= 0.4366\%
\end{aligned}$$

可以看出来，“中国航母”这个短语本身属于“政治”和“军事”分类的可能性最高，而属于“财经”的可能性最低。需要注意的是，我在上述公式使用了中文词便于你的理解，在真正的实现中，我们需要将中文词和中文分类名称转换为数字型的 ID，以提高系统的效率。

当然，一篇文章所包含的不同的单词数量要远远大于 2 个，之前如果我们只看“中国航母”这个短语，那么它属于“政治”和“军事”的概率基本一致。如果我们考虑更长的文章（也就是更多的单词），那么这个情况也许就会发生变化。为了支持更多的单词，我们将上述公式扩展为：

$$\begin{aligned} P(c|o) &= P(c|f_1, f_2, \dots, f_{n-1}, f_n) = P(c|f_1) \times P(c|f_2) \times \dots \times P(c|f_{n-1}) \times P(c|f_n) \\ &= \frac{P(f_1|c) \times P(c)}{P(f_1)} \times \frac{P(f_2|c) \times P(c)}{P(f_2)} \times \dots \times \frac{P(f_{n-1}|c) \times P(c)}{P(f_{n-1})} \times \frac{P(f_n|c) \times P(c)}{P(f_n)} \end{aligned}$$

这里需要注意一个很实际的问题：文章的篇幅很长，常常会导致非常多的  $P(f|c)$  连续乘积。而  $P(f|c)$  通常是非常小的数值，因此最后的乘积将快速趋近于 0 以至于计算机无法识别。这里可以使用我们之前提到的一些数学手法进行转换，比如取  $\log$ ，将小数转换为绝对值大于 1 的负数。这样的转换，虽然会改变每篇文章属于每个分类的概率之绝对值，但是并不会改变这些概率的相对大小。

## 总结

在这一讲中，我讲了一个文本分类系统的几个关键步骤，其中最重要的是自然语言的处理和分类模型的训练和预测。

自然语言的处理是关键的处理步骤，它将文本转换成计算机所能处理的数据。常见方法包括中文分词，英文的取词干和归一化，还有适用于各种语言的停用词、同义词和扩展词等。如果不考虑这些词出现的先后顺序，以及表达的深层次语义，那么我们就可以使用词包的方法，将大段的文章和语句转化成单词所组成的集合。之后，我们就能统计每个单词属于每个分类的条件概率，以及分类和单词的先验概率。

一旦将文章表示为单词的集合，我们就会发现，朴素贝叶斯的模型非常适合文章的分类。因为所有单词出现的词频都是离散值，非常适合统计概率。此外，许多新闻之类的文章本身也是跨了多个领域，因此有可能属于多个分类，朴素贝叶斯也能支持这点。我们针对“中国航母”这个短语进行了测试，发现其属于“政治”和“军事”分类的可能性最高。不过要注意的是，文章可能包含非常多的单词，朴素贝叶斯模型中的连续乘积会导致过小的值，甚至计算机都无法处理。为了避免这种情况，我们可以使用  $\log$  的数学变换。

## 思考题

你也许已经通过“中国航母”这个简单的例子，见识到了计算机自动分类的神奇功效。使用同样的分类模型和概率分布，你能否计算一下“美国电影”属于政治、军事、财经、体育和娱乐分类的概率，分别是多少？

欢迎留言和我分享，也欢迎你在留言区写下今天的学习笔记。你可以点击“请朋友读”，把今天的内容分享给你的好友，和他一起精进。



# 程序员的数学基础课

在实战中重新理解数学

黄申

LinkedIn 资深数据科学家



新版升级：点击「👤请朋友读」，10位好友免费读，邀请订阅更有**现金**奖励。

© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。

上一篇 22 | 朴素贝叶斯：如何让计算机学会自动分类？

下一篇 24 | 语言模型：如何使用链式法则和马尔科夫假设简化概率模型？

## 精选留言 (7)

写留言



冰冷的梦

2019-03-07

5

老师，我觉得这个 $p(c|f_i, f_j) = p(c|f_i) * p(c|f_j)$ 怪怪的，这个是怎么推导的啊？

作者回复: 这里是假设f1和f2相互独立, 所以有 $p(c|f1,f2)=p(c,f1,f2)/(p(f1,f2))=(p(c,f1)p(c,f2))/(p(f1)p(f2))=p(c|f1)p(c|f2)$



冰冷的梦

2019-03-12

👍 2

老师, 上一个问题是基于这个“这里是假设f1和f2相互独立, 所以有 $p(c|f1,f2)=p(c,f1,f2)/(p(f1,f2))=(p(c,f1)p(c,f2))/(p(f1)p(f2))=p(c|f1)p(c|f2)$ ”, 中间的等式:  $p(c,f1,f2)/(p(f1,f2))=(p(c,f1)p(c,f2))/(p(f1)p(f2))$ 这个等式成立的话我理解的是 $p(c,f1,f2) = p(c,f1)*p(c,f2)$ 应该是成立的, 这个是怎么推导的?

展开 ∨

作者回复: 你可以这么理解, 如果f1和f2独立, 那么f1不会影响f2的概率分布, 包括联合概率 $p(c,f)$ 和条件概率 $p(c|f)$



□

2019-02-06

👍 1

老师, 可能我太菜, 不会算。也许不是直接带公式吧。比如 $P(\text{美国}|\text{军事})$ , 根据条件概率公式 $=P(\text{美国}*\text{军事})/P(\text{军事})$ 。我不知道美国和军事是否应该看做独立。我就算了第一个 $P(\text{政治}|\text{美国电影})$ , 那个 $P(\text{电影}|\text{政治})$ 我取了第三个表中出现政治所有概率求和取平均值。算的0.07125%

展开 ∨

作者回复: 嗯, 以此类推到其他类就可以了



Jeson

2019-04-11

👍

很好, 看其他材料都没提分类结果是个相对值, 这里还提了原因, 最后还要进行一个归一化处理吧

作者回复: 是的, 为了可比较, 通常还可以进行归一化




冰冷的梦

2019-03-08



$p(c, f1, f2) = p(c, f1) \cdot p(c, f2)$  这两个相等是怎么推出来的？

作者回复: 我想你说的是  $p(c|f1, f2) = p(c|f1) \cdot p(c|f2)$  ？



qinggeouy...

2019-03-04



$P(\text{政治}|\text{美国电影})$

$= P(\text{政治}|\text{美国}) \cdot P(\text{政治}|\text{电影})$


$= [ P(\text{美国}|\text{政治}) \cdot P(\text{政治}) / P(\text{美国}) ] \cdot [ P(\text{电影}|\text{政治}) \cdot P(\text{政治}) / P(\text{电影}) ]$

$= [ 0.0028\% \cdot 20\% / 0.0028\% ] \cdot [ \dots \cdot 20\% / 0.0032\% ]$

...

展开 ∨

作者回复: 是的👌



zhaimy

2019-02-15



第一张表的先验概率应该是词频/总词频，而不是数量相除吧？比如政治，应该是 726898/2837891，而非20%

作者回复: 第一张表是指分类出现的概率，因此是以文章为单位来计算的。

